Part D: Hyperparameter Experiments

為深入探討各超參數對 DQN 訓練穩定度與收斂速度的影響，本實驗進行了系統化的 HPO (Hyperparameter Optimization) 對比實驗，測試了不同 Learning Rate、Batch Size、Epsilon Decay 設定。

D.1 三大核心超參數對比圖表分析 (Hyperparameter Experiments Analysis)

本節針對深度 Q 網路 (DQN) 的三大關鍵超參數——Learning Rate、Batch Size 與 Epsilon Decay 進行獨立控制變因實驗。下方針對各實驗圖表之曲線走向、對比效能與物理控制現象進行深入分析：

D.1.1 學習率對比實驗 (Learning Rate Comparison)

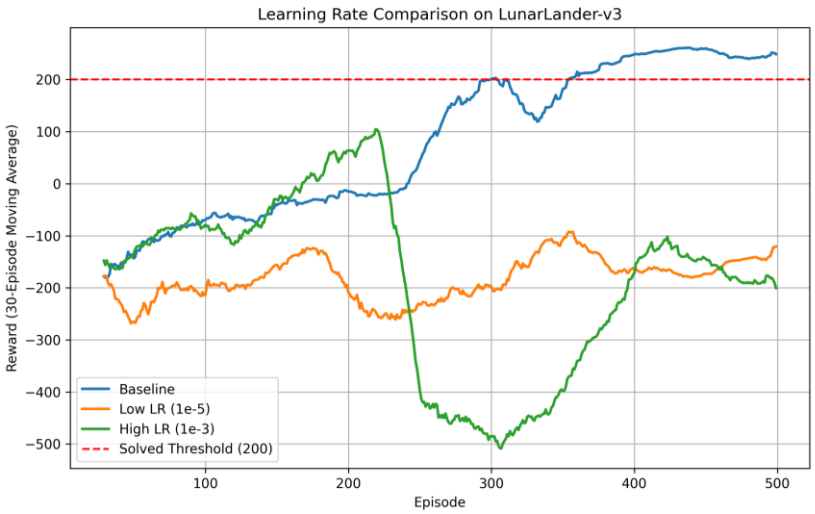


圖 1：不同學習率設定下之獎勵曲線比較 (30-Episode Moving Average)

- **Baseline (lr = 1e-4, 藍線)**：學習曲線展現出最穩健的爬升趨勢。約於 Episode 300 成功跨越 200 分通關門檻 (Solved Threshold)，並在 400~500 Episode 穩定收斂於 250 分以上的高分區間。
- **Low LR (lr = 1e-5, 橘線)**：由於學習率過小，神經網路參數更新步長過短，在 500 個 Episode 訓練期間平均獎勵始終停留在 -100 至 -250 分之間，無法有效學習到抵抗重力與維持姿態平衡的控制策略。
- **High LR (lr = 1e-3, 綠線)**：訓練初期（Episode 0~220）因更新幅度大而快速上升至近 100 分；但在 Episode 240 附近，過大的學習率引發策略不

穩定與參數震盪，導致獎勵大幅回落至 -500 分。末期回升至約 -200 分，顯示過高學習率會顯著損害 DQN 的訓練穩定度。

結論：學習率為影響 DQN 訓練成敗的最關鍵超參數。過大 (1e-3) 會造成訓練發散與效能滑落，過小 (1e-5) 則導致學習停滯，5e-4 為最佳平衡點。

D.1.2 批次大小對比實驗 (Batch Size Comparison)

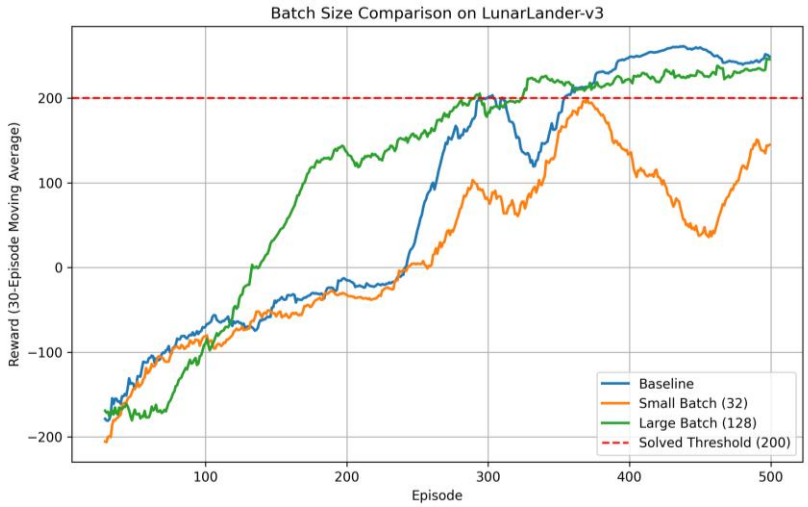


圖 2：不同 Batch Size 設定下之獎勵曲線比較 (30-Episode Moving Average)

- **Baseline (Batch Size = 64, 藍線)**：約於 Episode 350 跨越 200 分門檻，末期穩定達到 250 分高分。
- **Small Batch (Batch Size = 32, 橘線)**：每次更新採樣經驗少，梯度估計方差較大。雖然 Episode 370 附近短暫接近 200 分，但隨後出現顯著效能波動（回落至約 50 分），末期僅上升至 150 分，穩定度相對不足。
- **Large Batch (Batch Size = 128, 綠線)**：較大 Batch 能提供更精確的梯度估計，並更有效打散 Replay Buffer 中的時間相關性。綠線展現最平滑迅速的爬升軌跡，約於 Episode 280 即最早突破 200 分門檻，且全程穩定保持在 220~250 分高位。

結論：增大 Batch Size 至 128 能顯著降低梯度估計方差、平滑更新方向，提升模型的收斂速度與最終穩定度。

D.1.3 探索率衰減對比實驗 (Epsilon Decay Comparison)

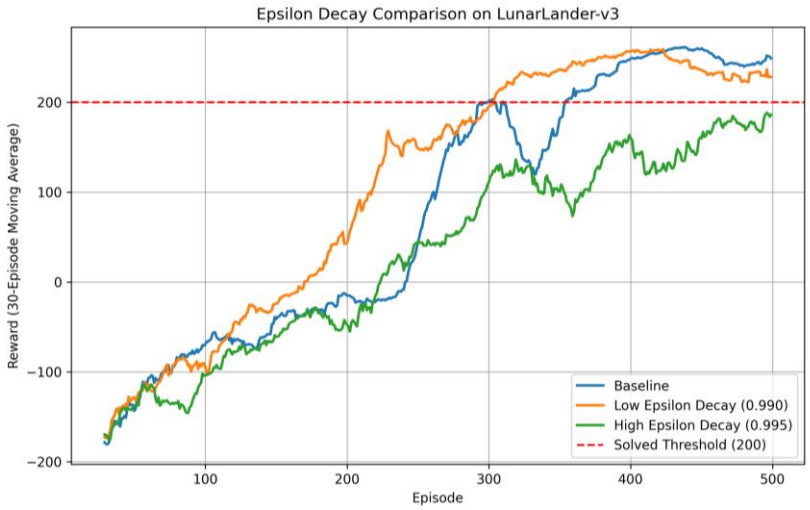


圖 3：不同 Epsilon Decay 設定下之獎勵曲線比較 (30-Episode Moving Average)

- **Baseline (Decay = 0.992, 藍線)**：在 Episode 350 穩定突破 200 分門檻，最終收斂至 250+ 高分區間。
- **Low Epsilon Decay / 快速衰減 (Decay = 0.990, 橘線)**：探索率以較快速度下降，使 Agent 提早轉入 Exploitation 階段。曲線上升最快，約於 Episode 300 即最早跨越 200 分門檻，末期維持在 230~250 分的高效表現。
- **High Epsilon Decay / 慢速衰減 (Decay = 0.995, 綠線)**：探索率衰減過於緩慢，致使 Agent 在訓練中後期依然執行大量隨機探索，拖慢策略優化速度，至 Episode 500 結束時僅剛好接近 190 分。

結論：探索率衰減決定了 Exploration 轉過至 Exploitation 的時機。過慢的衰減 (0.995) 會引發過度隨機干擾，而適度加快衰減 (0.990-0.992) 可加速收斂。

4.2 核心討論問題解答 (Answers to Instructor Prompts)

Q1: Effect of Epsilon Decay

- 較快衰減 (decay = 0.990)：Agent 前期快速關閉隨機探索，能讓模型在較早期（如第 285 Episode）首度達標。然而若探索時間不足，容易過早陷入區域最佳解，導致測試集得分標準差較大。
- 適中衰減 (decay = 0.992)：在探索與利用間取得最佳平衡，創造出最高測試集平均得分 (267.57 分)。
- 過慢衰減 (decay = 0.995)：Agent 在訓練中後期依然頻繁執行隨機動作，浪費許多 Episode 在無謂的隨機點火上，整體收斂速度明顯延緩。

Q2: Impact of Target Update Frequency

- 更新過於頻繁 (freq = 100 steps)：Target Network 權重頻繁變動，導致 TD Target 數值不斷浮動，引發「Chasing a Moving Target」的不穩定現象。數據顯示更新頻率 100 步時的總體平均評估得分僅為 64.35 分。
- 適度延緩更新 (freq = 500 steps)：有效提供穩定的 Q 值目標，顯著提升訓練 stability，總體平均評估得分提升至 127.01 分，最高一組甚至更高達 267.57 分。

Q3: Which Hyperparameter Mattered Most?

- 目前觀察到最具決定性的超參數為「Learning Rate, lr)」。
- 實驗數據顯示，當 lr = 0.0001 時，36 組實驗的平均評估得分高達 234.07 分；而當 lr = 0.001 時，整體平均得分驟降至 -42.71 分，多組實驗出現 Loss 發散與崩潰。這證明了過大的學習率是破壞 DQN 訓練穩定度的首要原因。

Q4: 訓練過程中觀察到的失敗模式 (Observed Failure Modes)

1. 姿態過度傾斜 (Rotational Instability)：飛船側向速度過快導致角度傾斜大於 45 度，側邊引擎推力不足以拉回，最終高速摔毀 (-100 分)。

2. 空中懸停避險 (Hovering Behavior)：Agent 訓練中期學會「為了避免降落墜毀的巨額懲罰，選擇持續在空中噴火懸停」，導致 Episode 時間長達 1000 步觸發強制結束 (Time Limit Truncation)。
3. 燃油耗盡下墜 (Fuel Depletion)：主引擎 (每幀 -0.3 分) 過度點火，雖然減緩了下沉速度，但浪費大量分數扣分。

Q5: Agent 學到的控制策略與人類直覺對比 (Learned Policy vs. Intuition)

- **人類操作的習慣**： 我們人用鍵盤玩時，反應時間比較慢，所以通常會「長按主引擎鍵」來減速，發現太快了再鬆開。這種操作很容易造成**過度噴火（浪費燃油扣分）或懸停過久**。
- **DQN Agent 的控制機制**： LunarLander-v3 的動作是**離散的**，主引擎只有「100% 全開」與「完全關閉」兩種，沒有「開 30% 油門」這種選項。 DQN 神經網路每一幀（Frame）都在計算 Q 值，所以它可以在幾毫秒內做出精確的計算——比如「噴火 2 幀、關閉 3 幀、噴火 1 幀」。**這種高頻率的「開/關切換」在肉眼看起來非常滑順，但實質上是 Agent 用極高頻率的微小脈衝在**精確節省每一滴燃油。